Business Analytics (114-1)
Final Term Report

第 12 組

第一章 執行摘要

項目	內容
研究目標	辨識造成航班延誤的關鍵因素，供現場營運決策及乘客航班選擇依據，主題涵蓋： a. 了解延誤風險如何隨時間條件、需求大小與航空公司等特性而改變 b. 建立延誤敏感度指標，觀察航空公司在壅塞情境下的營運韌性
資料背景	● 資料來源：美國運輸統計局官方 ● 資料內容：美國國內線航班延誤資料集 ● 時間範圍：2024 年 1 至 12 月 ● 資料量體：約 700 萬筆（考量計算效率，隨機抽樣 20 萬筆進行模型建立流程）
研究方法	● 模型類別：GLM - Logistic Regression ● 模型建立 ○ 變數選擇：透過 EDA 檢視變數分布，搭配航空實務邏輯，決定納入模型的解釋變數 ○ 模型優化：採用 ANOVA 和 AIC 準則進行模型比較，檢定主效果與交互作用的顯著性 ○ 模型檢驗與全母體回測 ● 敏感度指標建立：由模型結果決定壅塞情境的條件，延伸觀察各航空公司情境下的延誤風險
最終模型	● 被解釋變數：班機起飛是否延誤（二元變數 is_delayed，1 = 誤點、0 = 準點） ● 解釋變數 ○ 單變數項：時間（月份、時段、星期）、航線（航程、機場）、需求情境 (是否為尖峰時段、國定假日)、航空公司 ○ 交互作用項：航空公司 x 航程、航空公司 x 時段
關鍵發現	**1. 時間條件對於延誤率的影響** ● 晚間為延誤熱點：延誤率依時間不同，晚間 (evening) 延誤機率最高，其次是下午，上午最低 ● 假日和延誤呈負向關係：與直覺相反，國定假日 (holiday) 對延誤狀況呈現顯著的負向影響 (Estimate = -0.130)，顯示航空公司與機場在預期高流量的假期前，投入了有效的預防性資源，反而降低了延誤風險 ● 尖峰與假日無交互作用：研究發現尖峰時段 (peak-time) 與國定假日的關係是獨立的，無論假日與否，尖峰時段都容易延誤；假日的延誤狀況亦不因是否為尖峰而產生大幅改變 **2. 航空公司表現具有異質性** ● ANOVA 檢定顯示航空公司間延誤差異高度顯著： ● 「航空公司 x 尖峰時段」存在高度顯著的交互作用，說明不同航空公司對尖峰時段處理上顯著不同 ● 承前敘述，單一航空公司於不同時段的表現也可能存在差異，如西南航空 (WN)： ○ 離峰：WN 延誤率低，表現優於同業 ○ 尖峰：當進入晚間 x 尖峰時段，WN 的延誤率上升（交互項係數 1.627），延誤風險在高壓環境下顯著放大 **3. 營運韌性與敏感度分析** 本研究最後量化各航空公司的營運穩定性，指標可作為航空公司排班、調度及營運決策參考： ● 方法 ○ 定義一般情境與壅塞情境 (晚間＋非假日＋尖峰)，觀察航空公司在不同情境下的延誤率 ○ 以絕對敏感度衡量延誤機率增加的數量 ○ 以相對敏感度衡量延誤風險擴大的倍數 ● 洞察 ○ 低敏感度 (高穩定)：SkyWest (00)、Republic (YX) 與 Hawaiian (HA) ■ 多為區域型航空或特定市場航空，絕對敏感度最低 (< 0.1) ■ 即便環境變得很糟，延誤率只微幅增加，受壅塞影響小，展現極佳的穩定性 ○ 高敏感度 (低穩定)：西南航空 (WN) ■ 相對敏感度高達 4.08 倍，意即在壅塞情境下，搭乘西南航空遇到延誤的風險將上升 4 倍，再次驗證低成本、高周轉的經營模式在應對擁塞環境時較為脆弱

第二章 資料集與背景簡介

2.1 資料蒐集方法與背景

本報告所使用的資料集為 Kaggle 上的美國 2024 年國內線航班延誤資料集 (Flight Delay Dataset — 2024)，來源為美國運輸統計局 (TranStats On-Time Performance Database)，該資料集收錄 2024 年 1 至 12 月美國國內線航班數據，約 700 萬筆資料。

2.2 研究動機與目標

航班延誤一直是航空運輸業最受關注的營運議題之一，不僅直接影響旅客體驗與航空公司商譽，更涉及龐大的經濟成本，隨著航空旅運需求持續成長，機場容量與空域資源日益緊繃，航班延誤問題愈來愈複雜。本組期望透過統計建模與資料分析，辨識航班延誤的關鍵影響因素，了解延誤風險如何隨時間條件、需求大小與航空公司特性而改變，此外本組亦希望能建立延誤敏感度指標，量化航空公司在面對壅塞情境時延誤風險的變化幅度，能作為航空公司及機場在營運決策及旅客選擇航班時的參考。

2.3 分析架構

1. 資料前處理與探索性分析 (EDA)：了解變數類型、分布、關聯性，為模型進行有效之變數選擇
2. 模型建立：透過邏輯斯回歸建立基準模型，評估各變數的主效果
3. 交互作用檢定與模型優化：納入交互作用項，選擇最佳模型
4. 模型診斷驗證：進行 Overdispersion 檢驗、VIF 共線性檢測、殘差分析等診斷程序
5. 關鍵發現：回答研究問題
6. 研究結論

2.4 研究問題

1. 在控制其他營運條件後，不同的時間因素（如假期與週末、尖峰時段）和營運條件（如航程距離、航空公司）是否會顯著影響航班的延誤時長？
2. 不同航空公司之間的延誤狀況是否具有顯著差異？
3. 尖峰時段對延誤的影響，是否會因週末或假期等高客流量因子的不同而產生交互作用效應？
4. 不同航空公司在尖峰時段面對壅塞時，其延誤狀況是否有顯著差異？
5. 在容易延誤的時段，哪些航空公司的延誤風險較低、表現較為穩定？在控制航程距離、大型樞紐機場以及地區等因素後，前述在尖峰高風險時段表現較穩定的航空公司，是否仍較少延誤？
6. 延誤敏感度排名：建立航空公司的延誤敏感度排名

2.5 資料來源

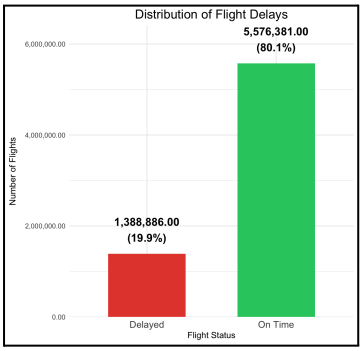
1. 資料集：Flight Delay Dataset — 2024, Hrishit Patil, Kaggle
   https://www.kaggle.com/datasets/hrishitpatil/flight-data-2024
2. 原始資料：TranStats On-Time Performance Database, Bureau of Transportation Statistics
   https://www.transtats.bts.gov/DL_SelectFields.aspx?gnoyr_VQ=FGJ&QO_fu146_anzr=b0-gvzr

第三章 模型建立

3.1 變數選擇

3.1.1 變數選取邏輯與前處理（含 EDA）

本研究旨在探討影響航班延誤的關鍵因素後，提供具體的管理建議。由於美國航空業界普遍以「出發延誤時間超過 15 分鐘」作為判斷是否延誤之標準，故本研究將**被解釋變數**設定為二元類別變數 is_delayed（1= 出發延誤，dep_delay >=15；0 = 準點出發，dep_delay < 15），並採用 GLM 中的 Logistic Regression 進行分析。



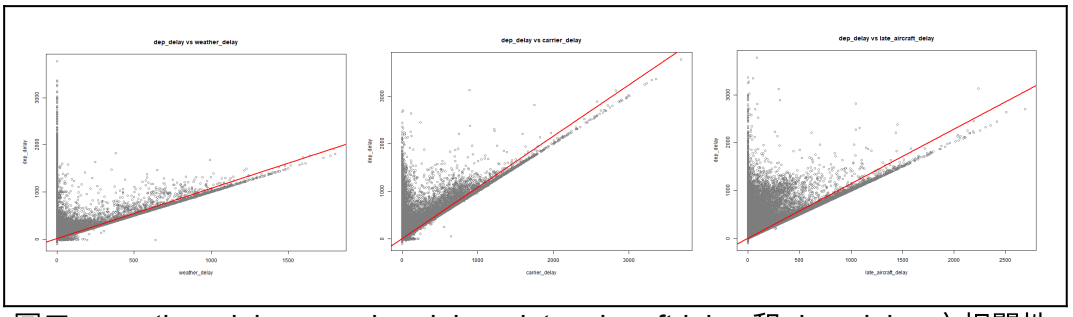
圖一：被解釋變數－延誤航班數量比例

為了確保模型之預測效度與統計穩健性，本研究首先根據 EDA 分析變數間的關聯性，再進行變數轉換與變數篩選：

1. 資料前處理與變數初步篩除

(1) **無關變數排除**：資料集含有 2024 年美國的完整航班資訊，為了單純針對實際起飛的航班進行分析，本組後續篩除取消航班 cancelled = 1 及轉機航班 diverted = 1 的樣本，並排除 cancelled, cancellation_code, diverted，不納入模型。

(2) **事後變數排除**：資料中包含各類延誤原因之時間變數，如：arrival_delay、carrier_delay、late_aircraftdelay（前機延誤延誤）、nas_delay（國家空域系統延誤）、security_delay（安檢延誤）、weather_delay（天氣延誤），其中 arrival_delay、carrier_delay、late_aircraft_delay 與 dep_delay 高度正相關，為避免時間順序錯置級內生性偏誤，本研究未將這些事後變數納入模型。



圖二：weather_delay、carrier_delay、late_aircraftdelay 和 dep_delay 之相關性

(3) **共線性檢測與排除**：透過相關係數矩陣可觀察變數間是否具共線性，檢測發現航程距離 distance 與飛行時間 air_time 存在高度共線性。考量航程距離為具備物理性質變數，較為直觀且穩定，故本研究保留 distance，不納入 air_time。

Variable	Correlation
arr_delay	0.97069385
carrier_delay	0.69559497
late_aircraft_delay	0.63884243
weather_delay	0.29703519
nas_delay	0.25028765
dep_time	0.12455261
wheels_off	0.11404711
crs_dep_time	0.10157258
taxi_out	0.05257094
security_delay	0.03066485
distance	0.01470914
air_time	0.01457065

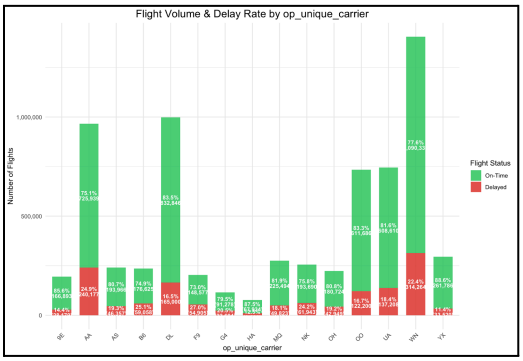
圖三：相關係數矩陣

2. 變數選取及變數轉換

本研究透過 EDA 檢視各變數與延誤結果 (is_delayed) 之關聯性，再搭配航空旅運實務邏輯，決定最終納入模型的解釋變數。以下依據 EDA 結果及商業邏輯考量，說明變數選取的邏輯。

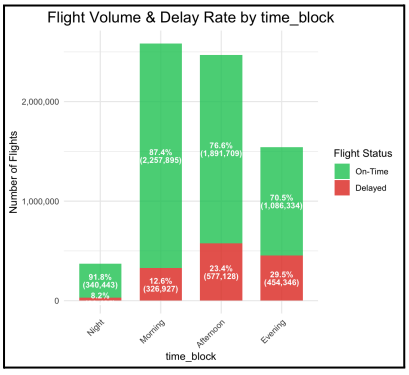
- **航空公司（op_unique_carrier）**：如圖四所示，各航空公司於全年航班樣本數分布並不均衡，其中以 WN（西南航空）之航班數量佔比最高，其次依序為 DL、AA 與 UA。不同航空公司在延誤占比上呈現差異，WN（西南航空）班次量最大，但延誤比例並非最高，而其他廉航如 NK、F9 或傳統航空

DL、AA 亦表現各異。由此可知，不同航空公司在機隊調度、資源配置與營運策略上有差異，可納入此變數以控制不同業者的體質差異。



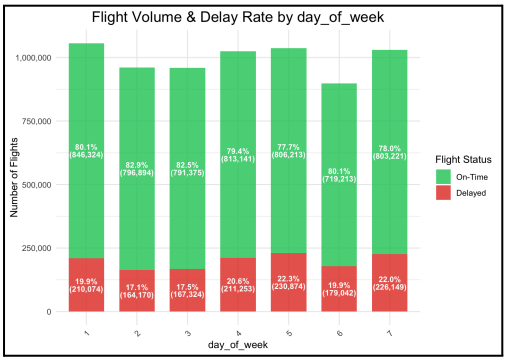
圖四：各航空公司之班次量與延誤分布

- **時段 (time_block)**： 由起程時間轉換成 Moring, afternoon, evening, night 四個時段。
經 EDA 分析，上午時段 (Morning) 雖擁有全天最高的航班總量（約 225 萬班次），但其延誤次數相較其他時段反而較低（32.6 萬）；反觀下午與晚間時段，延誤次數顯著攀升至 57.7 萬與 45.4 萬，本組認為延誤風險可能隨時間推移而累積，故本研究將此變數納入模型。



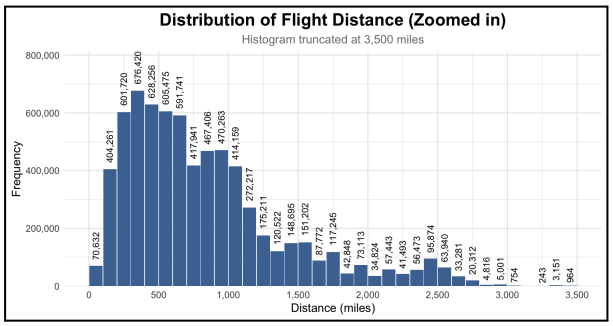
圖五：各時段之班機延誤分布

- **星期 (day_of_week)**：週五與週日之延誤班次數最高（皆突破 22 萬），顯著高於週二與週三的離峰延誤班機數（約 16 萬），反映商務與休閒旅運需求重疊所造成的週期性運量壓力，一週中不同星期延誤情形不同。

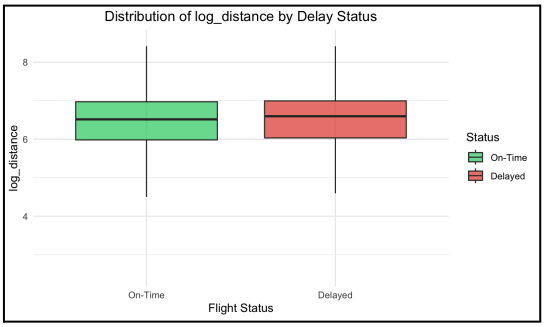


圖六：各星期之班機延誤分布

- **航程距離 (distance)**：根據圖七可觀察到航程距離呈現右偏分布，因此我們取對數 log(distance) 以修正資料之長尾分布特性；另外，從圖八可觀察延誤航班的數量分佈與總航班分布上兩者沒有很明顯差異，延誤的航班航程距離平均稍微較長，且其與 is_delayed 之相關係數偏低（0.02），但考量長程飛行涉及較複雜的航務操作與跨時區調度，為探討在控制其他變數後的淨影響，本研究仍保留此變數。

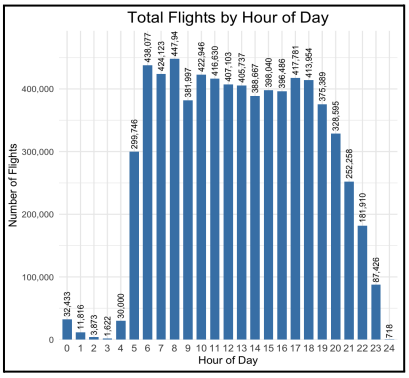


圖七：不同航程距離之班次量

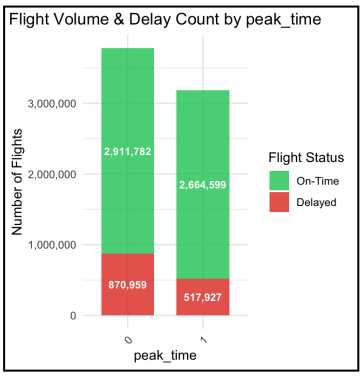


圖八：準點/延誤航班之航程距離箱型圖

- **尖峰時段 (peak_time)**：基於出發時間區間的班次量分布，我們判斷一天中共有三個時段航班量高的尖峰時段，分別為 6 點至 8 點、10點 至 13 點、17 點至 19 點，並據此建立二元變數（peak_time = 0, 1），以反映航空公司面對航班高度集中的處理能力，由圖十可知尖峰時段延誤比例 23.02% 高於非尖峰時段延誤比例 16.28%。

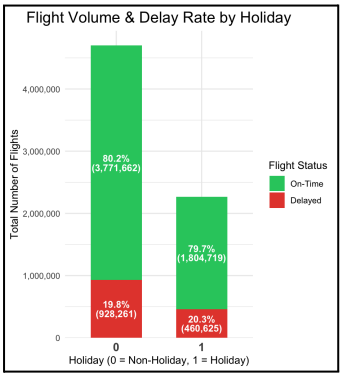


圖九：每小時班次數



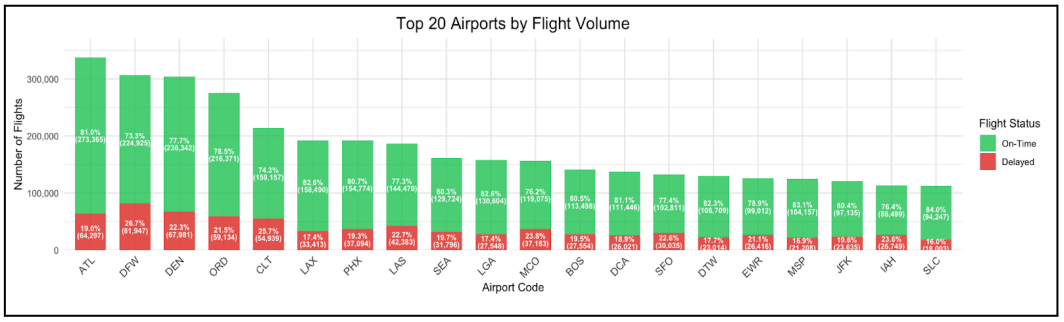
圖十：非尖峰/尖峰時段之班機延誤分布

- **假日 (holiday)**：本組認為國定假日單日機場人次較多，較可能導致機場壅塞進而提升航班延誤的情形，因此我們選定 26 個美國例假日（聖誕節、獨立日、感恩節、復活節...等）國定假期，據此建立二元變（holiday = 0, 1），以反映假日帶來的需求增加與營運壓力，由圖十一可觀察到假日延誤比例 20.3% 高於非假日 19.8%。



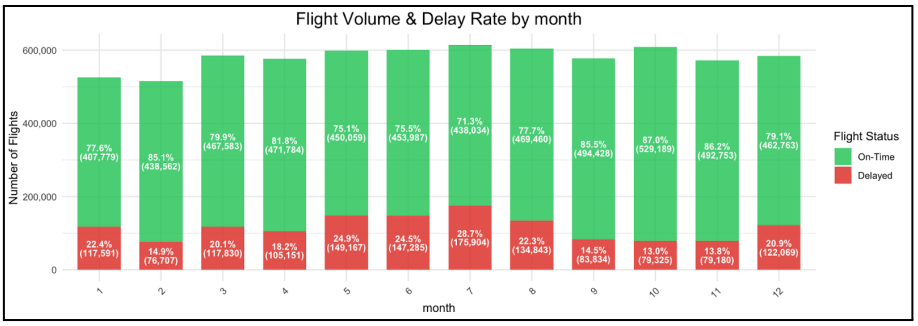
圖十一：非假日/假日之班機延誤分布

- **機場起訖機場 (origin_grp, dest_grp)**：航班延誤除受航空公司與時間因素影響外，亦高度仰賴機場本身的設施容量、跑道配置、空域限制與地理氣候條件，因此在模型納入起飛與降落機場，以捕捉機場層級之固定差異。



圖十二：前 20 名機場的航班數量分布

- **月份 (month)**：航班延誤風險可能隨季節變化而呈現系統性差異，如：冬季受降雪與惡劣天候影響、夏季則因旅遊旺季導致營運壓力上升，因此將月份納入模型，作為解釋變數以反映不同月份的結構性差異。

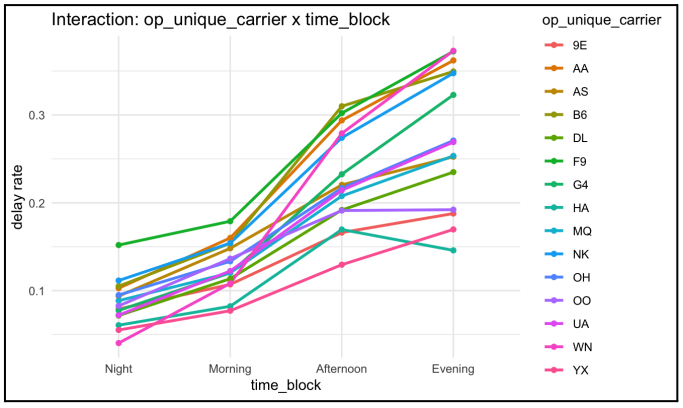


圖十三：各月份之班機延誤分布

3. 交互作用項考量

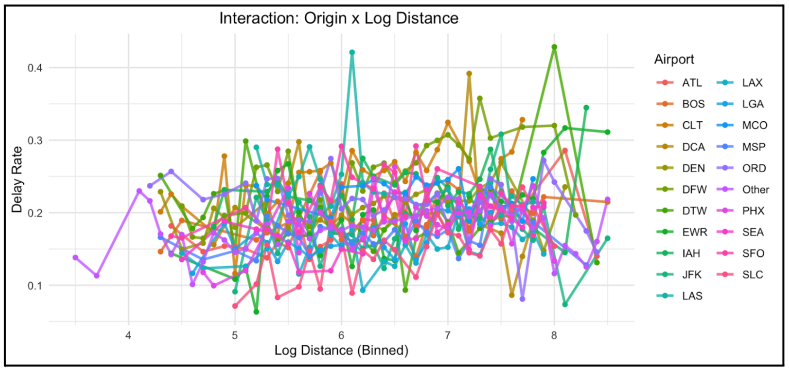
基於 EDA 初步探討變數間交互作用對延誤的影響。

- **航空公司 × 時段 (op_unique_carrier × time_block)**： 圖十四之折線圖顯示，不同航空的延誤率隨時段變化的趨勢並非平行， YX、HA 全天維持低延誤率，WN、AA 等航空延誤率則隨著時間大幅上升，顯示在模型中可以考慮納入兩者之交互作用，捕捉不同公司對時間壓力的敏感度差異。



圖十四：各航空公司於各時段之班機延誤率

- **機場 × 距離 (origin_grp × log_ month)**： 圖十五呈現各機場於不同航線距離下的延誤變化趨勢，非平行的趨勢線顯示機場在面對長、短程航班時，其延誤風險隨距離變化的幅度存在顯著差異。此一現象反映不同機場對航線距離的調節效果（E.g. 大型機場對長程航班可能較有處理經驗，延誤趨勢相對平緩；而以短程接駁為主的機場在執行長距離任務時，延誤的風險可能較大），納入機場與航線距離之交互項，有助於辨識不同機場在長短程航線上的異質性延誤表現。



圖十五：各機場在不同航線距離之班機延誤率

3.1.2 納入模型之變數

經過上述篩選考量，本研究預計納入模型之解釋變數及其商業意涵如下：

因子	敘述
時間	● time_block（時段）：探討一天中不同起飛時段對於航班延誤的影響 ● month（月份）：控制跨月份之季節性天候與需求變化 ● day_of_week（星期）：控制週間、週末不同旅運需求結構
營運	● op_unique_carrier（航空公司）：反映不同航空在營運策略與資源管理的差異
情境	● peak_time（尖峰時段）：反映航班高度集中時的營運壓力 ● holiday（假日）：控制假日時運量需求上升對機組作業的壓力
航線	● origin_grp、dest_grp（起訖機場）：控制不同機場在容量與設施條件上的結構性差異 ● log_distance（航程距離）：反程長短所隱含之作業複雜度差異

3.2 模型篩選與適配度診斷

3.2.0 建模資料

本資料集共包含約 700 萬筆美國航班紀錄，考量計算效率與模型估計可行性，因樣本數量已足以提供穩定估計，本研究自全體資料中隨機抽樣 20 萬筆樣本進行後續模型建立流程，在此資料規模下，模型係數與整體結論對樣本數具高度穩定性，進一步增加樣本僅會提高顯著性而不改變方向性結果。

3.2.1 Full model

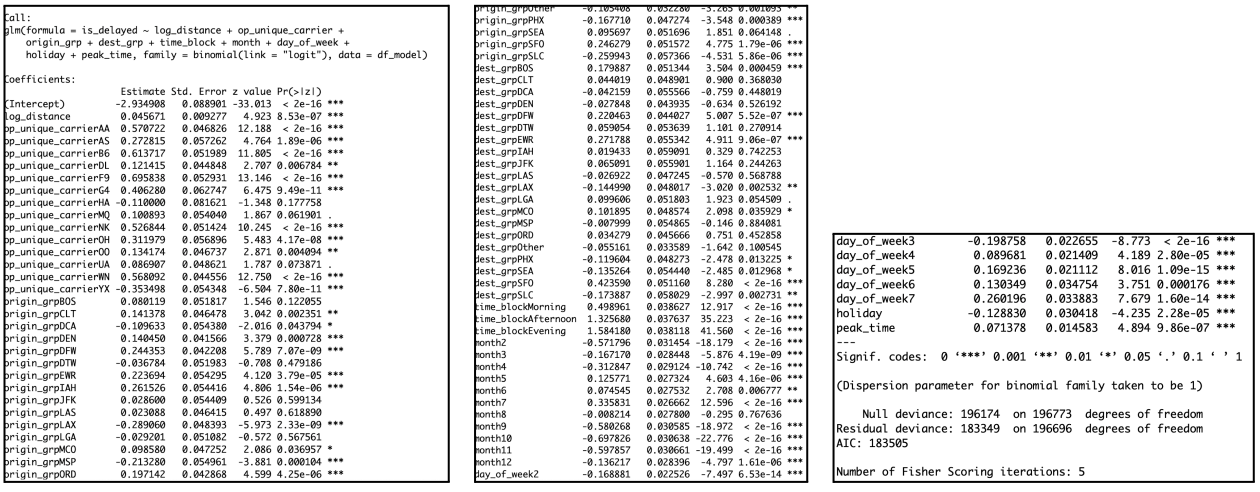
本研究首先建立包含上述所有變數之全模型（Full model）。模型如下：

```
Full_model = glm(formula = is_delayed ~ log_distance + op_unique_carrier +
                   origin_grp + dest_grp + time_block + month + day_of_week +
                   holiday + peak_time, family = binomial(link = "logit"), data = df_model)
```

$$\begin{aligned}\text{logit}(p_i) = \beta_0 &+ \beta_1 \ln(\text{Distance}_i) + \beta_2 \text{Peak}_i + \beta_3 \text{Holiday}_i \\ &+ \sum_c \beta_{C,c}\,\text{Carrier}_{i,c} + \sum_o \beta_{O,o}\,\text{OriginGroup}_{i,o} + \sum_d \beta_{D,d}\,\text{DestGroup}_{i,d} \\ &+ \sum_t \beta_{T,t}\,\text{TimeBlock}_{i,t} + \sum_m \beta_{M,m}\,\text{Month}_{i,m} + \sum_w \beta_{W,w}\,\text{DayOfWeek}_{i,w}\end{aligned}$$

圖十六：航班延誤率之初始邏輯斯迴歸模型設定

模型結果詳見圖十七，模型之 Residual Deviance 183349 優於空模型 196174 ，各個主要解釋變數（如時段、航空公司、航程距離）係數皆為顯著，雖然在大樣本情境下，多數解釋變數之係數本來就容易達到統計顯著，但本研究不以顯著性作為唯一判斷依據，而著重於效果方向與結構性差異之辨識。



```
Call:
glm(formula = is_delayed ~ log_distance + op_unique_carrier +
    origin_grp + dest_grp + time_block + month + day_of_week +
    holiday + peak_time, family = binomial(link = "logit"), data = df_model)

Coefficients:
                    Estimate Std. Error z value Pr(>|z|)
(Intercept)       -2.934908   0.088901 -33.013  < 2e-16 ***
log_distance       0.045671   0.009277   4.923 8.53e-07 ***
op_unique_carrierAA  0.570722   0.046826  12.188  < 2e-16 ***
op_unique_carrierAS  0.272815   0.057262   4.764 1.89e-06 ***
op_unique_carrierB6  0.613717   0.051989  11.805  < 2e-16 ***
op_unique_carrierDL  0.121415   0.044848   2.707 0.006784 **
op_unique_carrierF9  0.695838   0.052931  13.146  < 2e-16 ***
op_unique_carrierG4  0.406280   0.062747   6.475 9.49e-11 ***
op_unique_carrierHA -0.110000   0.081621  -1.348 0.177758
op_unique_carrierMQ  0.100893   0.054040   1.867 0.061901 .
op_unique_carrierNK  0.526844   0.051424  10.245  < 2e-16 ***
op_unique_carrierOH  0.311979   0.056896   5.483 4.17e-08 ***
op_unique_carrierOO  0.134174   0.046737   2.871 0.004094 **
op_unique_carrierUA  0.086907   0.048621   1.787 0.073871 .
op_unique_carrierWN  0.568092   0.044556  12.750  < 2e-16 ***
op_unique_carrierYX -0.353498   0.054348  -6.504 7.80e-11 ***
origin_grpBOS        0.080119   0.051817   1.546 0.122055
origin_grpCLT        0.141378   0.046478   3.042 0.002351 **
origin_grpDCA       -0.109633   0.054380  -2.016 0.043794 *
origin_grpDEN        0.140450   0.041566   3.379 0.000728 ***
origin_grpDFW        0.244353   0.042208   5.789 7.07e-09 ***
origin_grpDTW       -0.036784   0.051983  -0.708 0.479186
origin_grpEWR        0.223694   0.054295   4.120 3.79e-05 ***
origin_grpIAH        0.261526   0.054416   4.806 1.54e-06 ***
origin_grpJFK        0.028600   0.054409   0.526 0.599134
origin_grpLAS        0.023088   0.046415   0.497 0.618890
origin_grpLAX       -0.289060   0.048393  -5.973 2.33e-09 ***
origin_grpLGA       -0.029201   0.051082  -0.572 0.567561
origin_grpMCO        0.098580   0.047252   2.086 0.036957 *
origin_grpMSP       -0.213280   0.054961  -3.881 0.000104 ***
origin_grpORD        0.197142   0.042868   4.599 4.25e-06 ***
origin_grpOther     -0.105408   0.032280  -3.265 0.001095 **
origin_grpPHX       -0.167710   0.047274  -3.548 0.000389 ***
origin_grpSEA        0.095697   0.051696   1.851 0.064148 .
origin_grpSFO        0.246279   0.051572   4.775 1.79e-06 ***
origin_grpSLC       -0.259943   0.057366  -4.531 5.86e-06 ***
dest_grpBOS          0.179887   0.051344   3.504 0.000459 ***
dest_grpCLT          0.044019   0.048901   0.900 0.368030
dest_grpDCA         -0.042159   0.055566  -0.759 0.448019
dest_grpDEN         -0.027848   0.043935  -0.634 0.526192
dest_grpDFW          0.220463   0.044027   5.007 5.52e-07 ***
dest_grpDTW          0.059054   0.053639   1.101 0.270914
dest_grpEWR          0.271788   0.055342   4.911 9.06e-07 ***
dest_grpIAH          0.019433   0.059091   0.329 0.742253
dest_grpJFK          0.065091   0.055901   1.164 0.244263
dest_grpLAS         -0.026922   0.047245  -0.570 0.568788
dest_grpLAX         -0.144990   0.048017  -3.020 0.002532 **
dest_grpLGA          0.099606   0.051803   1.923 0.054509 .
dest_grpMCO          0.101895   0.048574   2.098 0.035929 *
dest_grpMSP         -0.007999   0.054865  -0.146 0.884081
dest_grpORD          0.034279   0.045666   0.751 0.452858
dest_grpOther       -0.055161   0.033589  -1.642 0.100545
dest_grpPHX         -0.119604   0.048273  -2.478 0.013225 *
dest_grpSEA         -0.135264   0.054440  -2.485 0.012968 *
dest_grpSFO          0.423590   0.051160   8.280  < 2e-16 ***
dest_grpSLC         -0.173887   0.058029  -2.997 0.002731 **
time_blockMorning    0.498961   0.038627  12.917  < 2e-16 ***
time_blockAfternoon  1.325680   0.037637  35.223  < 2e-16 ***
time_blockEvening    1.584180   0.038118  41.560  < 2e-16 ***
month2              -0.571796   0.031454 -18.179  < 2e-16 ***
month3              -0.167170   0.028448  -5.876 4.19e-09 ***
month4              -0.312847   0.029124 -10.742  < 2e-16 ***
month5               0.125771   0.027324   4.603 4.16e-06 ***
month6               0.074545   0.027532   2.708 0.006777 **
month7               0.335831   0.026662  12.596  < 2e-16 ***
month8              -0.008214   0.027800  -0.295 0.767636
month9              -0.580268   0.030585 -18.972  < 2e-16 ***
month10             -0.697826   0.030638 -22.776  < 2e-16 ***
month11             -0.597857   0.030661 -19.499  < 2e-16 ***
month12             -0.136217   0.028396  -4.797 1.61e-06 ***
day_of_week2        -0.168881   0.022526  -7.497 6.53e-14 ***
day_of_week3        -0.198758   0.022655  -8.773  < 2e-16 ***
day_of_week4         0.089681   0.021409   4.189 2.80e-05 ***
day_of_week5         0.169236   0.021112   8.016 1.09e-15 ***
day_of_week6         0.130349   0.034754   3.751 0.000176 ***
day_of_week7         0.260196   0.033883   7.679 1.60e-14 ***
holiday             -0.128830   0.030418  -4.235 2.28e-05 ***
peak_time            0.071378   0.014583   4.894 9.86e-07 ***
---
Signif. codes:  0 ‘***’ 0.001 ‘**’ 0.01 ‘*’ 0.05 ‘.’ 0.1 ‘ ’ 1

(Dispersion parameter for binomial family taken to be 1)

    Null deviance: 196174  on 196773  degrees of freedom
Residual deviance: 183349  on 196696  degrees of freedom
AIC: 183505

Number of Fisher Scoring iterations: 5
```

圖十七：Full model summary

為驗證模型之精簡性，進一步採用 AIC 準則改善模型，但觀察到多數不顯著變數主要是類別變數中的子項目，故利用 R 進行逐步迴歸篩選 (Stepwise Regression with Backward Selection)，但結果顯示，演算法篩選後的最佳模型與 Full model 完全一致，未剔除任何變數，顯示將原先選取的變數納入模型為合理做法。

此外，經 VIF 檢定，雖變數 holiday VIF 約 2.4 略高，推測可能與星期之間存在部分重疊，但仍遠低於常用判定門檻 10，顯示模型未呈現顯著多重共線性問題。

因此後續將以 Full model 作為 base model，參考 EDA 分析納入可能的交互作用擴充模型，藉此提升模型解釋力並貼近實務情境。

	GVIF	Df	GVIF^(1/(2*Df))
log_distance	1.353555	1	1.163424
op_unique_carrier	20.191028	14	1.113302
origin_grp	6.795164	20	1.049071
dest_grp	5.583599	20	1.043934
time_block	1.537088	3	1.074277
month	1.046518	11	1.002069
day_of_week	6.043063	6	1.161729
holiday	5.959525	1	2.441214
peak_time	1.487546	1	1.219650

圖十八：模型變數 VIF 數值結果

3.2.2 Full model + 航空公司 x 距離

加入此交互作用後，模型顯著優於僅主效果的模型（LRT: ΔDeviance = 107.27, df = 14, p < .001），顯示不同航空公司在面對飛行距離增加時，其延誤風險上升的幅度存在顯著差異。

```
Analysis of Deviance Table

Model 1: is_delayed ~ log_distance + op_unique_carrier + origin_grp +
    dest_grp + time_block + month + day_of_week + holiday + peak_time
Model 2: is_delayed ~ log_distance + op_unique_carrier + origin_grp +
    dest_grp + time_block + month + day_of_week + holiday + peak_time +
    log_distance:op_unique_carrier
  Resid. Df Resid. Dev Df Deviance  Pr(>Chi)
1    196696     183349
2    196682     183241 14   107.27 < 2.2e-16 ***
---
Signif. codes:  0 ‘***’ 0.001 ‘**’ 0.01 ‘*’ 0.05 ‘.’ 0.1 ‘ ’ 1
```

圖十九：model_int_dist ANOVA 分析

* AIC(model_base) = 183504.8；AIC(model_int_dist) = 183425.5

3.2.3 Full model + 航空公司 x 時段

加入此交互作用後，模型顯著優於僅主效果的模型（LRT: ΔDeviance = 608.21, df = 42, p < .001），顯示起飛時段對延誤機率的影響，會隨航空公司而有所不同。

```
Analysis of Deviance Table

Model 1: is_delayed ~ log_distance + op_unique_carrier + origin_grp +
    dest_grp + time_block + month + day_of_week + holiday + peak_time
Model 2: is_delayed ~ log_distance + op_unique_carrier + origin_grp +
    dest_grp + time_block + month + day_of_week + holiday + peak_time +
    op_unique_carrier:time_block
  Resid. Df Resid. Dev Df Deviance  Pr(>Chi)
1    196696     183349
2    196654     182741 42   608.21 < 2.2e-16 ***
---
Signif. codes:  0 ‘***’ 0.001 ‘**’ 0.01 ‘*’ 0.05 ‘.’ 0.1 ‘ ’ 1
```

圖二十：model_int_time ANOVA 分析

* AIC(model_base) = 183504.8；AIC(model_int_time) = 182980.5；ΔAIC = 524.3

3.2.4 Full model + 假日 x 航空公司

加入此交互作用後，ΔDeviance 13.3 < df 14，無證據顯示不同航空公司在假日的延誤行為存在顯著差異，因此後續不會將此交互作用放入最終模型。

```
Analysis of Deviance Table

Model 1: is_delayed ~ log_distance + op_unique_carrier + origin_grp +
    dest_grp + time_block + month + day_of_week + holiday + peak_time
Model 2: is_delayed ~ log_distance + op_unique_carrier + origin_grp +
    dest_grp + time_block + month + day_of_week + holiday + peak_time +
    op_unique_carrier:holiday
  Resid. Df Resid. Dev Df Deviance Pr(>Chi)
1    196696     183349
2    196682     183335 14   13.312   0.5021
```

圖二十一：model_int_holiday ANOVA 分析

* AIC(model_base) = 183504.8；AIC(model_int_holiday) = 183519.4

3.2.5 Full model + 尖峰時段 x 航空公司

加入此交互作用後，模型顯著優於僅主效果的模型（LRT: ΔDeviance = 131.58, df = 14, p < .001），顯示尖峰時段對航班延誤機率的影響，會因航空公司不同而有所差異。

```
Analysis of Deviance Table

Model 1: is_delayed ~ log_distance + op_unique_carrier + origin_grp +
    dest_grp + time_block + month + day_of_week + holiday + peak_time
Model 2: is_delayed ~ log_distance + op_unique_carrier + origin_grp +
    dest_grp + time_block + month + day_of_week + holiday + peak_time +
    op_unique_carrier:peak_time
  Resid. Df Resid. Dev Df Deviance  Pr(>Chi)
1    196696     183349
2    196682     183217 14   131.58 < 2.2e-16 ***
---
Signif. codes:  0 ‘***’ 0.001 ‘**’ 0.01 ‘*’ 0.05 ‘.’ 0.1 ‘ ’ 1
```

圖二十二：model_int_peak ANOVA 分析

* AIC(model_base) = 183504.8；AIC(model_int_peak) = 183401.2

3.2.6 Full model + 假日 x 尖峰時段

加入此交互作用後，模型未顯著改善（ΔDeviance 0.015 < df 1），無證據顯示假日對延誤機率的影響會因是否為尖峰時段而有所不同，因此後續不會將此交互作用放入最終模型。

```
Analysis of Deviance Table

Model 1: is_delayed ~ log_distance + op_unique_carrier + origin_grp +
    dest_grp + time_block + month + day_of_week + holiday + peak_time
Model 2: is_delayed ~ log_distance + op_unique_carrier + origin_grp +
    dest_grp + time_block + month + day_of_week + holiday + peak_time +
    holiday:peak_time
  Resid. Df Resid. Dev Df Deviance Pr(>Chi)
1    196696     183349
2    196695     183349  1 0.015622   0.9005
```

圖二十三：model_peak_holiday ANOVA 分析

* AIC(model_base) = 183504.8；AIC(model_peak_holiday) = 183506.7

接續前述分析結果，本文進一步將先前檢定中顯著之交互作用項同時納入模型，以評估其在整體模型中的聯合影響。

3.2.7 Full model + 航空公司 x 距離 + 航空公司 x 時段

將這兩個交互項納入模型後，模型顯著優於僅主效果的模型（LRT: ΔDeviance = 727.13, df = 56, p < .001），可更完整捕捉航空公司在不同營運條件下之延誤機率差異。

```
Analysis of Deviance Table

Model 1: is_delayed ~ log_distance + op_unique_carrier + origin_grp +
    dest_grp + time_block + month + day_of_week + holiday + peak_time
Model 2: is_delayed ~ log_distance + op_unique_carrier + origin_grp +
    dest_grp + time_block + month + day_of_week + holiday + peak_time +
    log_distance:op_unique_carrier + op_unique_carrier:time_block
  Resid. Df Resid. Dev Df Deviance  Pr(>Chi)
1    196696     183349
2    196640     182622 56   727.13 < 2.2e-16 ***
---
Signif. codes:  0 ‘***’ 0.001 ‘**’ 0.01 ‘*’ 0.05 ‘.’ 0.1 ‘ ’ 1
```

圖二十四：model_dist_time ANOVA 分析

* AIC(model_base) = 183504.8；AIC(model_dist_time) = 182889.6

3.2.8 Full model + 航空公司 x 距離 + 尖峰時段 x 航空公司

將這兩個交互項同時納入模型後，模型顯著優於僅主效果的模型（LRT: ΔDeviance = 240.05, df = 28, p < .001），解釋力有效提升。

```
Analysis of Deviance Table

Model 1: is_delayed ~ log_distance + op_unique_carrier + origin_grp +
    dest_grp + time_block + month + day_of_week + holiday + peak_time
Model 2: is_delayed ~ log_distance + op_unique_carrier + origin_grp +
    dest_grp + time_block + month + day_of_week + holiday + peak_time +
    log_distance:op_unique_carrier + op_unique_carrier:peak_time
  Resid. Df Resid. Dev Df Deviance  Pr(>Chi)
1    196696     183349
2    196668     183109 28   240.05 < 2.2e-16 ***
---
Signif. codes:  0 ‘***’ 0.001 ‘**’ 0.01 ‘*’ 0.05 ‘.’ 0.1 ‘ ’ 1
```

圖二十五：model_dist_peak ANOVA 分析

* AIC(model_base) = 183504.8；AIC(model_dist_peak) = 183320.7

3.2.9 Full model + 時段 x 航空公司 + 尖峰時段 x 航空公司

將這兩個交互項同時納入模型後，模型顯著優於僅主效果的模型（LRT: ΔDeviance = 627.57, df = 56, p < .001），航空公司在不同時間結構與營運壓力條件下，延誤行為存在差異。

```
Analysis of Deviance Table

Model 1: is_delayed ~ log_distance + op_unique_carrier + origin_grp +
    dest_grp + time_block + month + day_of_week + holiday + peak_time
Model 2: is_delayed ~ log_distance + op_unique_carrier + origin_grp +
    dest_grp + time_block + month + day_of_week + holiday + peak_time +
    op_unique_carrier:time_block + op_unique_carrier:peak_time
  Resid. Df Resid. Dev Df Deviance  Pr(>Chi)
1    196696     183349
2    196640     182725 56   623.57 < 2.2e-16 ***
---
Signif. codes:  0 ‘***’ 0.001 ‘**’ 0.01 ‘*’ 0.05 ‘.’ 0.1 ‘ ’ 1
```

圖二十六：model_time_peak ANOVA 分析

* AIC(model_base) = 183504.8；AIC(model_time_peak) = 182993.2

3.2.10 Full model + 航空公司 x 時段 + 假日 x 航空公司 + 尖峰時段 x 航空公司

納入這三項交互作用後，模型顯著優於僅主效果的模型（LRT: ΔDeviance = 240.05, df = 28, p < .001），模型解釋力有效提升。

```
Analysis of Deviance Table

Model 1: is_delayed ~ log_distance + op_unique_carrier + origin_grp +
    dest_grp + time_block + month + day_of_week + holiday + peak_time
Model 2: is_delayed ~ log_distance + op_unique_carrier + origin_grp +
    dest_grp + time_block + month + day_of_week + holiday + peak_time +
    op_unique_carrier:time_block + log_distance:op_unique_carrier +
    op_unique_carrier:peak_time
  Resid. Df Resid. Dev Df Deviance  Pr(>Chi)
1    196696     183349
2    196626     182607 70   741.97 < 2.2e-16 ***
---
Signif. codes:  0 ‘***’ 0.001 ‘**’ 0.01 ‘*’ 0.05 ‘.’ 0.1 ‘ ’ 1
```

圖二十七：model_all ANOVA 分析

* AIC(model_base) = 183504.8；AIC(model_all) = 182902.8

3.2.11 Final model

根據下圖 AIC 比較表中，可以判斷在顯著存在交互作用的模型中，AIC 最低的是 model_dist_time ，顯示此模型在解釋航空公司延誤行為差異的表現最佳，故選定為最終模型。

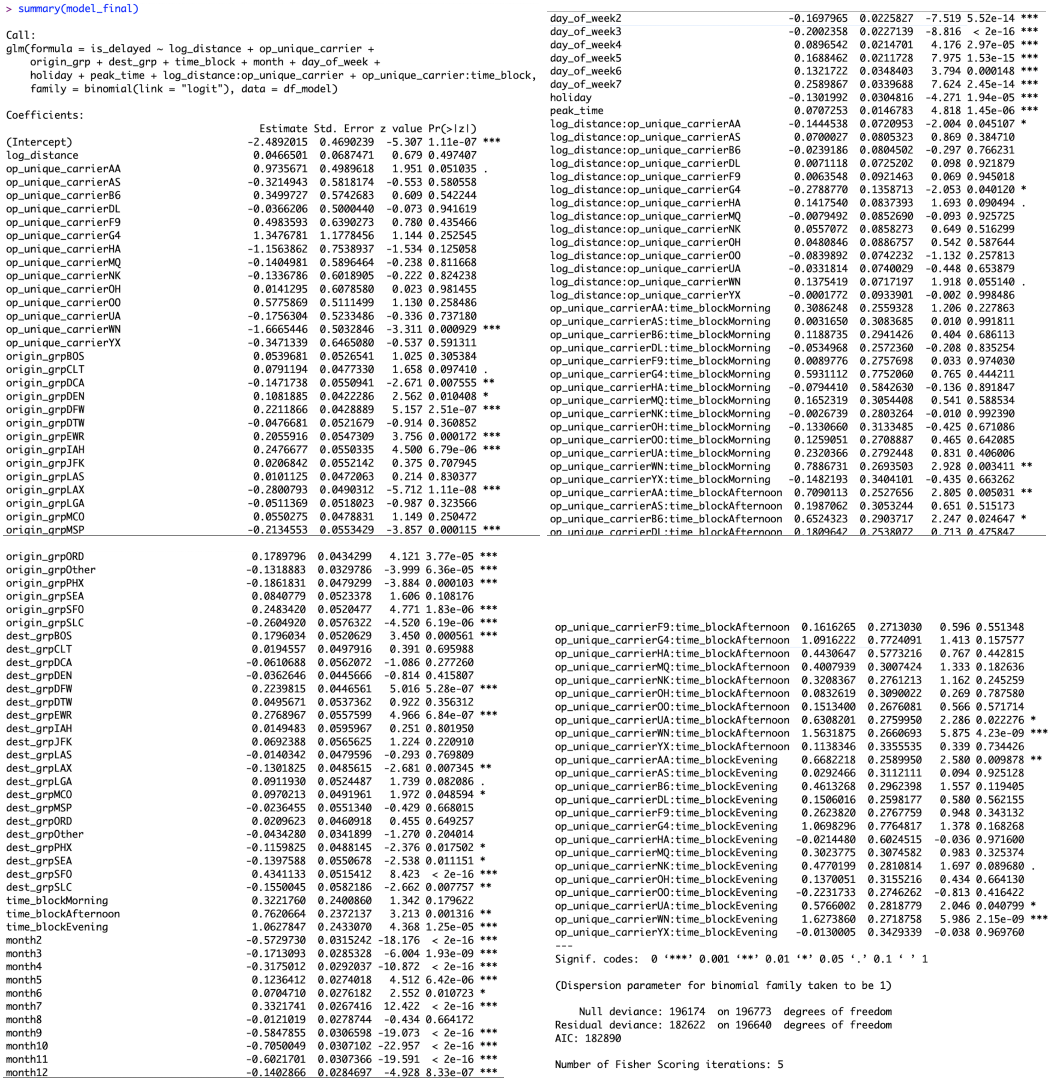
模型	AIC
Full model	183504.8
model_dist_time = Full model + 航空公司 x 距離 + 航空公司 x 時段	182889.6
Full model + 航空公司 x 距離 + 尖峰時段 x 航空公司	183320.7
Full model + 時段 x 航空公司 + 尖峰時段 x 航空公司	182993.2
Full model + 航空公司 x 時段 + 假日 x 航空公司 + 尖峰時段 x 航空公司	182902.8

```
final_model = glm(formula = is_delayed ~ log_distance + op_unique_carrier +
                  origin_grp + dest_grp + time_block + month + day_of_week +
                  holiday + peak_time + log_distance:op_unique_carrier + op_unique_carrier:time_block,
                  family = binomial(link = "logit"), data = df_model)
```

$$
\begin{aligned}
\operatorname{logit}(p_i) = {} & \beta_0 + \beta_1 \ln(\text{Distance}_i) + \beta_2 \text{Peak}_i + \beta_3 \text{Holiday}_i \\
& + \sum_c \beta_{C,c}\, \text{Carrier}_{i,c} + \sum_o \beta_{O,o}\, \text{OriginGroup}_{i,o} + \sum_d \beta_{D,d}\, \text{DestGroup}_{i,d} \\
& + \sum_t \beta_{T,t}\, \text{TimeBlock}_{i,t} + \sum_m \beta_{M,m}\, \text{Month}_{i,m} + \sum_w \beta_{W,w}\, \text{DayOfWeek}_{i,w} \\
& + \sum_c \gamma_c \Big(\ln(\text{Distance}_i) \cdot \text{Carrier}_{i,c} \Big) + \sum_c \sum_t \delta_{c,t} \Big(\text{Carrier}_{i,c} \cdot \text{TimeBlock}_{i,t} \Big)
\end{aligned}
$$

圖二十八：航班延誤率之最終邏輯斯迴歸模型設定

最終模型摘要如下：



```
> summary(model_final)

Call:
glm(formula = is_delayed ~ log_distance + op_unique_carrier +
    origin_grp + dest_grp + time_block + month + day_of_week +
    holiday + peak_time + log_distance:op_unique_carrier + op_unique_carrier:time_block,
    family = binomial(link = "logit"), data = df_model)

Coefficients:
                                          Estimate Std. Error z value Pr(>|z|)
(Intercept)                             -2.4892015  0.4690239  -5.307 1.11e-07 ***
log_distance                             0.0466501  0.0687471   0.679 0.497407
op_unique_carrierAA                      0.9735671  0.4989618   1.951 0.051035 .
op_unique_carrierAS                     -0.3214943  0.5818174  -0.553 0.580558
op_unique_carrierB6                      0.3499727  0.5742683   0.609 0.542244
op_unique_carrierDL                     -0.0366206  0.5000440  -0.073 0.941619
op_unique_carrierF9                      0.4983593  0.6390273   0.780 0.435466
op_unique_carrierG4                      1.3476781  1.1778456   1.144 0.252545
op_unique_carrierHA                     -1.1563862  0.7538937  -1.534 0.125058
op_unique_carrierMQ                     -0.1404981  0.5896464  -0.238 0.811668
op_unique_carrierNK                     -0.1336786  0.6018905  -0.222 0.824238
op_unique_carrierOH                      0.0141295  0.6078580   0.023 0.981455
op_unique_carrierOO                      0.5775869  0.5111499   1.130 0.258486
op_unique_carrierUA                     -0.1756304  0.5233486  -0.336 0.737180
op_unique_carrierWN                     -1.6665446  0.5032846  -3.311 0.000929 ***
op_unique_carrierYX                     -0.3471339  0.6465080  -0.537 0.591311
origin_grpBOS                            0.0539681  0.0526541   1.025 0.305384
origin_grpCLT                            0.0791194  0.0477330   1.658 0.097410 .
origin_grpDCA                           -0.1471738  0.0550941  -2.671 0.007555 **
origin_grpDEN                            0.1081885  0.0422286   2.562 0.010408 *
origin_grpDFW                            0.2211866  0.0428889   5.157 2.51e-07 ***
origin_grpDTW                           -0.0476681  0.0521679  -0.914 0.360852
origin_grpEWR                            0.2055916  0.0547309   3.756 0.000172 ***
origin_grpIAH                            0.2476677  0.0550335   4.500 6.79e-06 ***
origin_grpJFK                            0.0206842  0.0552142   0.375 0.707945
origin_grpLAS                            0.0101125  0.0472063   0.214 0.830377
origin_grpLAX                           -0.2800793  0.0490312  -5.712 1.11e-08 ***
origin_grpLGA                           -0.0511369  0.0518023  -0.987 0.323566
origin_grpMCO                            0.0550275  0.0478831   1.149 0.250472
origin_grpMSP                           -0.2134553  0.0553429  -3.857 0.000115 ***
origin_grpORD                            0.1789796  0.0434299   4.121 3.77e-05 ***
origin_grpOther                         -0.1318883  0.0329786  -3.999 6.36e-05 ***
origin_grpPHX                           -0.1861831  0.0479299  -3.884 0.000103 ***
origin_grpSEA                            0.0840779  0.0523378   1.606 0.108176
origin_grpSFO                            0.2483420  0.0520477   4.771 1.83e-06 ***
origin_grpSLC                           -0.2604920  0.0576322  -4.520 6.19e-06 ***
dest_grpBOS                              0.1796034  0.0520629   3.450 0.000561 ***
dest_grpCLT                              0.0194557  0.0497916   0.391 0.695988
dest_grpDCA                             -0.0610688  0.0562072  -1.086 0.277260
dest_grpDEN                             -0.0362646  0.0445666  -0.814 0.415807
dest_grpDFW                              0.2239815  0.0446561   5.016 5.28e-07 ***
dest_grpDTW                              0.0495671  0.0537362   0.922 0.356312
dest_grpEWR                              0.2768967  0.0557599   4.966 6.84e-07 ***
dest_grpIAH                              0.0149483  0.0595967   0.251 0.801950
dest_grpJFK                              0.0692388  0.0565625   1.224 0.220910
dest_grpLAS                             -0.0140342  0.0479596  -0.293 0.769809
dest_grpLAX                             -0.1301825  0.0485615  -2.681 0.007345 **
dest_grpLGA                              0.0911930  0.0524487   1.739 0.082086 .
dest_grpMCO                              0.0970213  0.0491961   1.972 0.048594 *
dest_grpMSP                             -0.0236455  0.0551340  -0.429 0.668015
dest_grpORD                              0.0209623  0.0460918   0.455 0.649257
dest_grpOther                           -0.0434280  0.0341899  -1.270 0.204014
dest_grpPHX                             -0.1159825  0.0488145  -2.376 0.017502 *
dest_grpSEA                             -0.1397588  0.0550678  -2.538 0.011151 *
dest_grpSFO                              0.4341133  0.0515412   8.423  < 2e-16 ***
dest_grpSLC                             -0.1550045  0.0582186  -2.662 0.007757 **
time_blockMorning                        0.3221760  0.2400860   1.342 0.179622
time_blockAfternoon                      0.7620664  0.2372137   3.213 0.001316 **
time_blockEvening                        1.0627847  0.2433070   4.368 1.25e-05 ***
month2                                  -0.5729730  0.0315242 -18.176  < 2e-16 ***
month3                                  -0.1713093  0.0285328  -6.004 1.93e-09 ***
month4                                  -0.3175012  0.0292037 -10.872  < 2e-16 ***
month5                                   0.1236412  0.0274018   4.512 6.42e-06 ***
month6                                   0.0704710  0.0276182   2.552 0.010723 *
month7                                   0.3321741  0.0267416  12.422  < 2e-16 ***
month8                                  -0.0121019  0.0278744  -0.434 0.664172
month9                                  -0.5847855  0.0306598 -19.073  < 2e-16 ***
month10                                 -0.7050049  0.0307102 -22.957  < 2e-16 ***
month11                                 -0.6021701  0.0307366 -19.591  < 2e-16 ***
month12                                 -0.1402866  0.0284697  -4.928 8.33e-07 ***
day_of_week2                            -0.1697965  0.0225827  -7.519 5.52e-14 ***
day_of_week3                            -0.2002358  0.0227139  -8.816  < 2e-16 ***
day_of_week4                             0.0896542  0.0214701   4.176 2.97e-05 ***
day_of_week5                             0.1688462  0.0211728   7.975 1.53e-15 ***
day_of_week6                             0.1321722  0.0348403   3.794 0.000148 ***
day_of_week7                             0.2589867  0.0339688   7.624 2.45e-14 ***
holiday                                 -0.1301992  0.0304816  -4.271 1.94e-05 ***
peak_time                                0.0707253  0.0146783   4.818 1.45e-06 ***
log_distance:op_unique_carrierAA        -0.1444538  0.0720953  -2.004 0.045107 *
log_distance:op_unique_carrierAS         0.0700027  0.0805323   0.869 0.384710
log_distance:op_unique_carrierB6        -0.0239186  0.0804502  -0.297 0.766231
log_distance:op_unique_carrierDL         0.0071118  0.0725202   0.098 0.921879
log_distance:op_unique_carrierF9         0.0063548  0.0921463   0.069 0.945018
log_distance:op_unique_carrierG4        -0.2788770  0.1358713  -2.053 0.040120 *
log_distance:op_unique_carrierHA         0.1417540  0.0837393   1.693 0.090494 .
log_distance:op_unique_carrierMQ        -0.0079492  0.0852690  -0.093 0.925725
log_distance:op_unique_carrierNK         0.0557072  0.0858273   0.649 0.516299
log_distance:op_unique_carrierOH         0.0480846  0.0886757   0.542 0.587644
log_distance:op_unique_carrierOO        -0.0839892  0.0742232  -1.132 0.257813
log_distance:op_unique_carrierUA        -0.0331814  0.0740029  -0.448 0.653879
log_distance:op_unique_carrierWN         0.1375419  0.0717197   1.918 0.055140 .
log_distance:op_unique_carrierYX        -0.0001772  0.0933901  -0.002 0.998486
op_unique_carrierAA:time_blockMorning    0.3086248  0.2559328   1.206 0.227863
op_unique_carrierAS:time_blockMorning    0.0031650  0.3083685   0.010 0.991811
op_unique_carrierB6:time_blockMorning    0.1188735  0.2941426   0.404 0.686113
op_unique_carrierDL:time_blockMorning   -0.0534968  0.2572360  -0.208 0.835254
op_unique_carrierF9:time_blockMorning    0.0089776  0.2757698   0.033 0.974030
op_unique_carrierG4:time_blockMorning    0.5931112  0.7752060   0.765 0.444211
op_unique_carrierHA:time_blockMorning   -0.0794410  0.5842630  -0.136 0.891847
op_unique_carrierMQ:time_blockMorning    0.1652319  0.3054408   0.541 0.588534
op_unique_carrierNK:time_blockMorning   -0.0026739  0.2803264  -0.010 0.992390
op_unique_carrierOH:time_blockMorning   -0.1330660  0.3133485  -0.425 0.671086
op_unique_carrierOO:time_blockMorning    0.1259051  0.2708887   0.465 0.642085
op_unique_carrierUA:time_blockMorning    0.2320366  0.2792448   0.831 0.406006
op_unique_carrierWN:time_blockMorning    0.7886731  0.2693503   2.928 0.003411 **
op_unique_carrierYX:time_blockMorning   -0.1482193  0.3404101  -0.435 0.663262
op_unique_carrierAA:time_blockAfternoon  0.7090113  0.2527656   2.805 0.005031 **
op_unique_carrierAS:time_blockAfternoon  0.1987062  0.3053244   0.651 0.515173
op_unique_carrierB6:time_blockAfternoon  0.6524323  0.2903717   2.247 0.024647 *
op_unique_carrierDL:time_blockAfternoon  0.1809642  0.2538072   0.713 0.475847
op_unique_carrierF9:time_blockAfternoon  0.1616265  0.2713030   0.596 0.551348
op_unique_carrierG4:time_blockAfternoon  1.0916222  0.7724091   1.413 0.157577
op_unique_carrierHA:time_blockAfternoon  0.4430647  0.5773216   0.767 0.442815
op_unique_carrierMQ:time_blockAfternoon  0.4007939  0.3007424   1.333 0.182636
op_unique_carrierNK:time_blockAfternoon  0.3208367  0.2761213   1.162 0.245259
op_unique_carrierOH:time_blockAfternoon  0.0832619  0.3090022   0.269 0.787580
op_unique_carrierOO:time_blockAfternoon  0.1513400  0.2676081   0.566 0.571714
op_unique_carrierUA:time_blockAfternoon  0.6308201  0.2759950   2.286 0.022276 *
op_unique_carrierWN:time_blockAfternoon  1.5631875  0.2660693   5.875 4.23e-09 ***
op_unique_carrierYX:time_blockAfternoon  0.1138346  0.3355535   0.339 0.734426
op_unique_carrierAA:time_blockEvening    0.6682218  0.2589950   2.580 0.009878 **
op_unique_carrierAS:time_blockEvening    0.0292466  0.3112111   0.094 0.925128
op_unique_carrierB6:time_blockEvening    0.4613268  0.2962398   1.557 0.119405
op_unique_carrierDL:time_blockEvening    0.1506016  0.2598177   0.580 0.562155
op_unique_carrierF9:time_blockEvening    0.2623820  0.2767759   0.948 0.343132
op_unique_carrierG4:time_blockEvening    1.0698296  0.7764817   1.378 0.168268
op_unique_carrierHA:time_blockEvening   -0.0214480  0.6024515  -0.036 0.971600
op_unique_carrierMQ:time_blockEvening    0.3023775  0.3074582   0.983 0.325374
op_unique_carrierNK:time_blockEvening    0.4770199  0.2810814   1.697 0.089680 .
op_unique_carrierOH:time_blockEvening    0.1370051  0.3155216   0.434 0.664130
op_unique_carrierOO:time_blockEvening   -0.2231733  0.2746262  -0.813 0.416422
op_unique_carrierUA:time_blockEvening    0.5766002  0.2818779   2.046 0.040799 *
op_unique_carrierWN:time_blockEvening    1.6273860  0.2718758   5.986 2.15e-09 ***
op_unique_carrierYX:time_blockEvening   -0.0130005  0.3429339  -0.038 0.969760
---
Signif. codes:  0 ‘***’ 0.001 ‘**’ 0.01 ‘*’ 0.05 ‘.’ 0.1 ‘ ’ 1

(Dispersion parameter for binomial family taken to be 1)

    Null deviance: 196174  on 196773  degrees of freedom
Residual deviance: 182622  on 196640  degrees of freedom
AIC: 182890

Number of Fisher Scoring iterations: 5
```

圖二十九： Final model summary

最終模型之 McFadden pseudo-R^2 為 0.069，整體解釋度有限，但此數值在大樣本之 logistic regression 與航班延誤此類高噪音行為資料中屬合理範圍，航班延誤還會受到即時天氣狀況、其他人為營運因素的影響，然而天氣及其他營運因素並未納入此次模型，因此本研究不以整體解釋度作為主要評估指標，而著重於解釋變數方向性與交互作用所反映之結構性差異。

為了驗證模型效力，本組將抽樣模型套用至全年度完整資料集進行回測，結果顯示全年度資料集預估延誤之準確率達 80.13%，與訓練樣本的準確率 80.24% 僅有 0.10% 的微幅差異，證明模型沒有出現過度擬合，擁有不錯的預測能力，足以代表整體航班營運情形。

3.3 模型檢驗

3.3.1 Overdispersion 檢驗

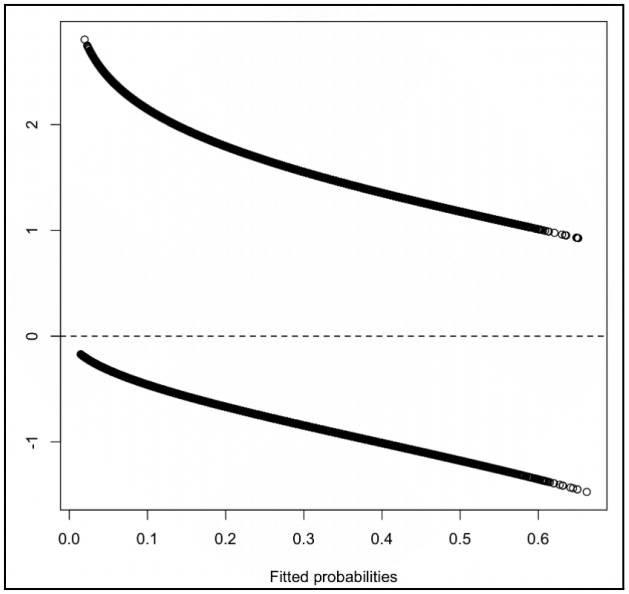
本組以 Pearson residuals 計算 dispersion parameter，結果 φ = 1.007402，非常接近 1，顯示模型殘差變異與 binomial 分布假設一致，未發現顯著 overdispersion，因此未採用 quasi-binomial 修正。

3.3.2 Deviance goodness-of-fit

本組以 residual deviance 進行 goodness-of-fit 檢定，p_gof = 1，未顯示顯著 lack-of-fit。
但在大樣本 logistic regression 中，deviance goodness-of-fit 檢定的鑑別力有限，因此將此結果當作基本檢查，輔以 overdispersion 檢定與 AIC-based 模型選擇來評估模型合理性。

3.3.3 Deviance residual vs fitted

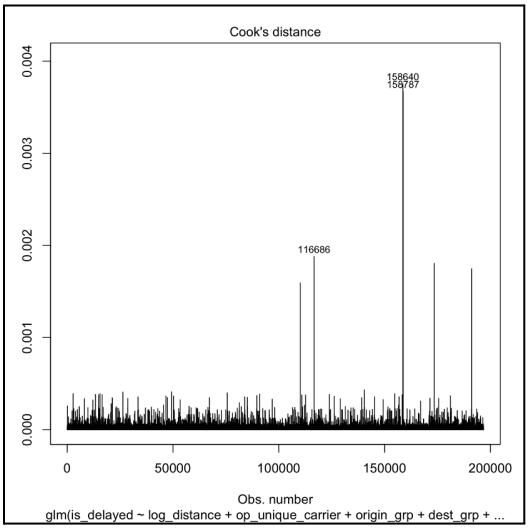
由於本研究之應變數為二元變數，logistic regression 的 deviance residual 會呈現上下兩群，為此模型之結構性特徵。而由於樣本數龐大，殘差分布呈現平滑穩定的樣態。整體而言，未觀察到明顯的系統性失配或異常殘差。



圖三十：Deviance Residuals vs Fitted Probabilities

3.3.4 Cook's distance

根據圖 X，大多數觀測值之 Cook’s distance 接近 0，沒有能對模型會產生明顯影響的極端觀測值；有鑑於樣本數龐大，較少觀測值呈現高 Cook’s distance 屬正常現象，單一觀測值較難對模型產生顯著影響。



圖三十一：離群值檢驗 (Cook’s distance)

3.3.5 Null model vs Final model 的 drop-in-deviance

與只含截距的 Null model 比較，drop-in-deviance 檢定顯示最終模型 deviance 顯著下降（Deviance = 13552, p < .001），代表具有顯著的統計解釋貢獻。

```
Analysis of Deviance Table

Model 1: is_delayed ~ 1
Model 2: is_delayed ~ log_distance + op_unique_carrier + origin_grp +
    dest_grp + time_block + month + day_of_week + holiday + peak_time +
    log_distance:op_unique_carrier + op_unique_carrier:time_block
  Resid. Df Resid. Dev  Df Deviance  Pr(>Chi)
1    196773     196174
2    196640     182622 133    13552 < 2.2e-16 ***
---
Signif. codes:  0 ‘***’ 0.001 ‘**’ 0.01 ‘*’ 0.05 ‘.’ 0.1 ‘ ’ 1
```

圖三十二：Null model vs Final model drop-in-deviance summary

第四章 關鍵發現

4.1 時間因素與營運條件對航班出發延誤風險之影響

Q. 不同的時間因素與營運條件是否會顯著影響航班出現出發延誤的狀況？
（航程距離、假日/非假日、尖峰/非尖峰、平日/週末、出發時段...）

以下根據 full model summary（圖十八）與 final model summary（圖二十九），說明各個變數是否對於延誤有顯著影響，將先透過不含交互作用的 full model 來檢視各變數的整體影響力，再透過含交互作用 final model 說明個體差異。

(1) 具普遍性顯著影響的變數

以下變數在模型中無設定交互作用，可從 final model 判斷其普遍的影響：

- 平日/週末 (day_of_week)： 呈現顯著影響
  相較於星期一，週間不同日子的延誤風險有顯著不同（均顯著, p < 0.001），其中週二、週三為負向係數（Estimates = -0.17, -0.20），週四至週日則呈現顯著正向係數 ，且係數隨週末接近而上升，顯示隨著週末旅運需求增加，延誤風險會隨之顯著提高。
- 假日 (holiday)： 呈現顯著負向影響（Estimate = -0.130, p < 0.001）
  這表示在控制其他變數後，假日期間的航班延誤風險反而較低，推測可能與航空公司及機場在假期前已預估會有大量人潮，因此投入較多資源進行預防性調度有關。
- 尖峰時段 (peak_time)： 呈現顯著正向影響（Estimate = 0.071, p < 0.001）
  顯示在一天當中的流量尖峰時刻，受限於機場容量與空域擁擠，航班普遍面臨較高的延誤風險。

(2) 航程距離（log_distance）

- 根據 full model 結果，航程距離會產生顯著正向影響（Estimate = 0.046, OR = 1.047），代表在不區分航空公司的情況下，長程航班普遍面臨較高的作業不確定性，使延誤風險上升。
- 根據加入航空公司 x 航程距離交互項的 final_model 結果，距離效果因航空公司而異，如 G4 飛長程時，反而延誤風險顯著下降（Estimate = -0.279）。

(3) 出發時段（time_block）

- 根據 full model 結果，出發時段對於延誤皆有顯著影響，且延誤風險高至低排列為：Evening (Estimate = 1.584) > Afternoon (Estimate = 1.326) > Morning (Estimate = 0.499) > Night (baseline)，晚間最有可能出現延誤。
- 根據加入航空公司 x 出發時段交互項的 final_model 結果，顯示出發時段對延誤的影響會因航空公司而異，特定航空公司在下午與晚間面臨較高的延誤壓力，例如：AA（美國航空） 在下午時段的延誤風險顯著高於基準航空（Estimate = 0.709, p = 0.005）；WN（西南航空） 在晚間時段的延誤狀況更嚴峻，顯著高於基準航空（Estimate = 1.627, p < 0.001） ，顯示該公司在晚間調度上面臨極大的壓力。

整體而言，原先預期下列變數都會產生顯著正向影響，在尖峰時段、週末、假期與較長航程的航班更容易發生延誤，實作後發現大部分如預期，僅假期呈現負向影響。

4.2 航空公司間延誤風險之顯著差異

Q. 不同航空公司之間的延誤狀況是否具有顯著差異？

是，不同航空公司之間會出現顯著差異。

本組使用 ANOVA 檢定比較 final_model 與移除航空公司變數的簡化模型，結果顯示移除航空公司效果後 Deviance 顯著上升（=141.8, df 14, p-value < 0.001），代表加入航空公司變數可顯著提升模型解釋力，意即航空公司營運特性為航班延誤的關鍵因素之一，不同航空公司之間的延誤存在極度顯著的差異。

```
Analysis of Deviance Table

Model 1: is_delayed ~ log_distance + origin_grp + dest_grp + time_block +
    month + day_of_week + holiday + peak_time + log_distance:op_unique_carrier +
    op_unique_carrier:time_block
Model 2: is_delayed ~ log_distance + op_unique_carrier + origin_grp +
    dest_grp + time_block + month + day_of_week + holiday + peak_time +
    log_distance:op_unique_carrier + op_unique_carrier:time_block
  Resid. Df Resid. Dev Df Deviance  Pr(>Chi)
1    196654     182763
2    196640     182622 14    141.8 < 2.2e-16 ***
---
Signif. codes:  0 ‘***’ 0.001 ‘**’ 0.01 ‘*’ 0.05 ‘.’ 0.1 ‘ ’ 1
```

圖三十三：檢定航空公司效果

4.2.1 延誤風險最低與最高之航空公司

在模型中控制其他變數後，相對於基準航空公司延誤 odds 最低的三家和最高的三家航空公司如圖三十四所示，其中：

- 延誤風險最低航空：WN 西南航空
  在基準情境下表現最為優異，主效應 odds ratio 為 0.19（Estimate = -1.667），且具備高度統計顯著性，顯示其基礎調度能力優於同業。
  不過結合交互作用項分析可發現，其優勢於晚間航班時會大幅抵銷（Estimate = 1.627），變成與基準航空相近的水準，說明航空公司的表現並非絕對的優劣，表現好壞的排名會根據不同時段、航線結構變動。
- 延誤風險高航空：AA 美國航空
  航空公司 AA 及 G4 的 odds ratio 最高分別為 2.65 與 3.85，但 AA 為邊緣顯著，G4 未達統計顯著，雖為最高值但無法斷定與基準航空有顯著差異。

```
> best3
                              OR     OR_LCL    OR_UCL      p_value
op_unique_carrierWN 0.1888987 0.07044209 0.5065537 0.0009285158
op_unique_carrierHA 0.3146211 0.07179138 1.3788066 0.1250579681
op_unique_carrierYX 0.7067107 0.19903666 2.5092866 0.5913113197
```

```
> worst3
                              OR    OR_LCL    OR_UCL    p_value
op_unique_carrierOO 1.781734 0.6542613  4.852152 0.25848649
op_unique_carrierAA 2.647371 0.9956296  7.039339 0.05103495
op_unique_carrierG4 3.848479 0.3825649 38.714457 0.25254525
```

圖三十四：延誤風險最低與最高的三家公司

4.3 尖峰時段與假日之交互作用分析

Q. 尖峰時段的影響力是否因假日不同而有所差異？

不會，本組於段落 3.2.6 評估了尖峰時段與假日的交互作用，了解延誤風險是否會因為尖峰時段與假日與否而產生差異：

- AIC：183504.8 → 183506.7（上升）
- Deviance：不顯著

由此可見尖峰時段與假期的交互作用並不顯著，表示這兩個變數對延誤的效果是獨立存在。無論當天是否為假日，尖峰時段都會以相同的幅度提升延誤風險，而假期效應也不會因時段是否壅塞而產生大幅度改變，兩者沒有協同效應。在航班管理上，各航空公司或機場可參考此結果，尖峰時段 SOP、假日 SOP 不須因為不同時間點而特別改變。

4.4 航空公司與尖峰時段之交互作用分析

Q. 不同航空公司在尖峰時段面對壅塞時，其延誤狀況是否有顯著差異？

是，本組於段落 3.2.5 對航空公司與尖峰時段的交互作用進行評估，希望了解不同航空公司在尖峰時段所呈現的延誤風險差異，結果如下：

- AIC：183504.8 → 183401.2（下降）
- Deviance：高度顯著

由此可見尖峰時段與航空公司的交互作用高度顯著，不同航空公司之間對於尖峰時段的抗壓力與處理方式不同，可能有些航空公司尖峰時段排班緊密、地勤不足，導致延誤更容易出現；但某些航空公司運作效率高，在尖峰時段不會額外增加延誤風險。

而此差異已涵蓋在 final model 航空公司 x 時段的交互項中，可交叉比對觀察各航空公司的差異，如：WN（西南航空）在對應尖峰的晚間時段，其交互項係數顯著為 1.627，證明其在面對尖峰高流量時的抗壓性較弱。

4.5 高風險時段下航空公司營運穩定性分析

Q. 在容易延誤的時段，哪些航空公司的延誤風險較低、表現較為穩定？
Q. 在控制航程距離、大型樞紐機場及地區等因素後，前述在尖峰高風險時段表現較穩定的航空公司，是否仍較少延誤？

4.5.1 高延誤風險時段之穩定航空公司辨識

本研究進一步探討在容易延誤的時段中，哪些航空公司能維持較低的延誤風險並展現較高的營運穩定性。為達到公平比較，我們設定統一的基準情境，將所有非研究焦點的變數固定，再比較不同航空公司在高風險時段的準點表現。

在預測航空公司於不同時段的延誤風險之前，本組先決定了一組具代表性的控制變因，以排除外生環境因素影響。本研究的控制設定如下：

- log_distance：設定為樣本的中位數，作為典型航程距離
- origin_grp、dest_grp：皆設定為 "Other"，代表排除大型樞紐機場或特定地區差異
- month：選取延誤率與全年平均最接近的月份（3 月）
- day_of_week：選取延誤率最接近全年平均的星期別（星期一）
- holiday：設定為 0（平日）
- peak_time：設定為 0（非尖峰），採用一般需求條件作為基準
- time_block：先比較四個時段的平均延誤率，將延誤率高於全年平均者（0.199）視為容易延誤時段，為 Afternoon (0.234) 與 Evening (0.293)

藉由固定上述變數，可排除季節性、地理環境、需求波動等外在因素，使航空公司之間的比較單純反映其自身調度能力與營運品質。
本組將 Afternoon 與 Evening 視為延誤率顯著偏高的高風險時段，在前述控制變因下，我們對資料中每一家航空公司建立「航空公司 x 高風險時段」的情境資料表，並利用最終邏輯斯迴歸模型進行延誤機率之預測，再將預測結果彙整為航空公司層級的指標，包含：

- mean_peak：兩個高風險時段的平均延誤風險（愈低愈好）。
- sd_peak：兩時段間的延誤風險標準差（愈小穩定性愈高）。
- min_peak / max_peak：分別對應 Afternoon 與 Evening 兩者中表現最佳與最差的情境。

依據 mean_peak 排序後，可辨識出在高延誤風險時段，前五家具備穩定控制能力之航空公司分別為 YX、HA、00、9E、MQ，前三名皆為區域型航空，由於先前為了排除大型機場流量管制等外部干擾，聚焦於航空公司自身的作業效率，將機場條件控制為非樞紐機場，反映在排除了樞紐壅塞影響後，區域航空在點對點運作上的靈活性與作業流程，使其具備極高的穩定性。

```
# A tibble: 5 × 5
  op_unique_carrier mean_peak sd_peak max_peak min_peak
  <fct>                <dbl>   <dbl>    <dbl>    <dbl>
1 YX                   0.132 0.0141     0.142    0.122
2 HA                   0.167 0.0161     0.178    0.156
3 OO                   0.169 0.00732    0.174    0.164
4 9E                   0.171 0.0300     0.192    0.150
5 MQ                   0.194 0.0223     0.210    0.178
```

圖三十五：高風險時段延誤風險比較

4.5.2 一般情境下之穩定度驗證

在確認高風險時段的表現差異後，我們希望進一步檢驗，那些在尖峰高風險時段較穩定的航空公司，在一般時段是否仍保持較低延誤風險。因此，我們將 time_block 更新為非高風險時段（Morning），維持相同的控制條件（holiday = 0、peak_time = 0 等），再進行一次延誤機率預測，作為各航空公司的 baseline 延誤率。

高風險與非高風險時段比較結果：

- 兩者之預測平均延誤機率呈現中高度正相關（r = 0.7460307）。
- 在高風險時段中被判定為穩定的航空公司，其一般情境下的預測延誤率仍明顯較低（穩定組約 0.0918，非穩定組約 0.12）

由結果可知，在高風險時段中表現良好的航空公司，在一般營運條件下亦能維持較佳的準點水準，代表這些航空公司具備較成熟的排班與調度能力，其營運水準在高壓環境及日常營運皆有優勢。

```
  is_stable avg_peak avg_baseline
  <lgl>        <dbl>        <dbl>
1 FALSE        0.262       0.120
2 TRUE         0.166       0.0918
```

圖三十六：控制變數後預測延誤率比較

4.6 航空公司延誤敏感度分析

為評估航空公司在高壓壅塞的條件下的延誤風險變化，本組根據 final model 建立延誤敏感度指標，以衡量航空公司在面對壅塞情境時延誤風險上升的程度，敏感度愈低代表其營運調度能力較強、受壅塞衝擊的程度較小、表現較為穩定。

4.6.1 情境設定與敏感度指標定義

綜合 4.5.1 及上述分析，晚間、非假日及尖峰需求均對延誤風險有顯著提升效果，因此分成：

- 壅塞情境（congested）：Evening × holiday = 0 × peak_time = 1
- 離峰情境（baseline）：Morning × holiday = 1 × peak_time = 0

在控制其他外生因素（航程距離、機場群組、月份、星期別）後，分別估計兩種情境下每家航空公司的預測延誤機率。

對每家航空公司分別估計兩種情境下的延誤機率後，本研究定義：

- 絕對敏感度（sensitivity_abs）：congested − baseline
- 相對敏感度（sensitivity_rel）：congested ÷ baseline

絕對敏感度反映延誤機率增加的數量，相對敏感度反映延誤風險擴大的倍數。

4.6.2 航空公司延誤敏感度比較

根據理想情境及高壓壅塞情境之比較結果，各航空公司的絕對敏感度由小到大排序如下：

	op_unique_carrier	baseline	congested	sensitivity_abs	sensitivity_rel
	<fct>	<dbl>	<dbl>	<dbl>	<dbl>
1	OO	0.104	0.174	0.0695	1.67
2	YX	0.0571	0.151	0.0938	2.64
3	HA	0.0679	0.165	0.0973	2.43
4	9E	0.0904	0.203	0.113	2.25
5	AS	0.102	0.231	0.129	2.25
6	MQ	0.0882	0.221	0.133	2.51
7	DL	0.0869	0.230	0.143	2.65
8	UA	0.0781	0.235	0.157	3.00
9	OH	0.108	0.289	0.181	2.68
10	B6	0.120	0.329	0.210	2.75
11	F9	0.147	0.362	0.216	2.47
12	G4	0.101	0.317	0.216	3.14
13	AA	0.123	0.339	0.217	2.77
14	NK	0.111	0.341	0.230	3.07
15	WN	0.0920	0.375	0.283	4.08

圖三十七：絕對敏感度排序

由圖三十七可發現下列兩項重要且有趣的洞見：

1. 00 (SkyWest)、YX (Republic)、HA (Hawaiian) 為敏感度最小的前三名，延誤風險在進入壅塞情境時僅小幅增加，絕對敏感度小於 0.1，表示其排班與地面調度較能抵禦壅塞衝擊，營運穩定度高，且與 4.5.2 的結果一致，是相同的三家航空公司，可見延誤敏感度能夠實際反映航空公司在極端條件下延誤風險的變化。
    - 其中 00 (SkyWest) 雖在 4.2 主效應分析中呈現較高 OR 值，但因未達統計顯著性 (p=0.258)，統計上無法認定其表現劣於同業。然而，敏感度分析進一步證實，其在壅塞情境下的風險增加幅度為全體最小，這表示 SkyWest 並非一間高風險航空，而是一家表現平穩、具備高抗壓性的航空公司。
2. WN (西南航空) 為敏感度最大的航空公司，顯示雖在基準情境下表現優異 (0.092)，但一旦進入壅塞情境，其延誤風險暴增至 0.375，相對風險放大高達 4.08 倍，表示其在高壓環境下容錯空間小，對於環境非常敏感，呼應 4.4 對於航空公司 x 尖峰時段交互作用的分析結果，這也顯示低成本、高周轉模式在應對系統性壅塞的脆弱。

第五章 研究結論

5.1 結論

本研究以 2024 年美國國內航班資料為基礎，透過邏輯斯迴歸模型分析航班出發延誤的影響因素，並納入交互作用以呈現不同航空公司在特定營運情境下的表現差異。研究結果顯示，航班延誤非由單一因素造成，而是由時間條件、需求壅塞與航空公司營運特性共同決定，且其影響具有明顯的情境依賴性。

1. 整體來看，尖峰時段與週末會顯著提高延誤風險，反映高需求時段下的機場容量限制；相對地，假日則呈現負向效果，顯示航空公司與機場能透過事前規劃有效降低延誤機率。
2. 進一步執行交互作用分析後，發現航程距離與出發時段對延誤風險的影響會因航空公司而異，納入交互作用後，這些變數的主效果不再一致，顯示延誤風險高度取決於航空公司自身的排班結構與調度能力。另外，各航空公司的相對表現會隨時段與壅塞程度而改變，部分航空公司在一般情境下表現良好，但在晚間或尖峰時段，其延誤風險大幅上升，顯示營運模式在高壓環境下的脆弱性。
3. 透過高風險時段的穩定性分析與延誤敏感度指標，本組辨識出不同航空公司在壅塞情境下的表現差異：部分區域型航空在高風險與一般情境下皆能維持較低延誤風險，反映其營運流程的穩定性；而部分高周轉航空公司（如西南航空）對壅塞情境高度敏感，延誤風險在高壓環境下顯著放大。

綜上所述，本組認為航班延誤風險為一種情境依賴的營運結果，航空公司在進行績效評估或營運決策時，不宜僅以平均延誤率衡量，而應同時考量其在高需求與壅塞環境下的穩定性與抗壓能力，方能更貼近實務營運現實。

5.2 研究限制與未來研究方向

5.2.1 研究限制

1. **天氣資料缺乏**

本研究最主要限制在於無法納入天氣相關變數，航班延誤高度受降雪、雷雨、強風等天氣狀況影響，而這些因素僅能透過月份、機場等代理變數間接捕捉。原始資料雖包含 weather_delay 變數，但屬事後記錄，納入模型將造成時間順序錯置與內生性偏誤，天氣資料的缺乏會導致部分解釋變數的效應被高估或低估。

2. **樣本抽樣**
   本組因考慮自約 700 萬筆完整資料中隨機抽樣 20 萬筆進行分析，雖然經回測證明此樣本足以提供穩定估計，但仍可能會存在稀有事件捕捉不足（如小型航空公司樣本數較少）或極端情況遺漏的問題。

5.2.2 未來研究方向

1. **整合即時天氣資料**
   未來應蒐集即時天氣資料，納入起降機場的天氣條件（溫度、降雨量、風速、能見度等）與航線沿途氣象資料，更精確地分離天氣因素與營運因素的效應，並建立條件性預測模型，評估不同天氣條件下營運因素的影響。
2. **考量前序航班與連鎖延誤效應**
   航班延誤常源自於同一架飛機執行前一趟任務時的延誤，但目前的模型將每個航班視為獨立事件，未能納入前序航班所造成的連鎖延誤影響，未來可將前序航班之即時狀態與預計抵達資訊納入分析，以納入延誤在航班網絡中的連鎖效應，提升模型對實際營運情境的解釋力。
3. **納入機隊與人力資源變數**
   除了天氣資料外，亦可蒐集航空公司層級的營運資料，包括機隊組成（機型分布、平均機齡、備用飛機數量）、人力配置（飛行員與空服員排班密度、訓練水準）與維護能力，以解釋航空公司間延誤差異的根本原因。